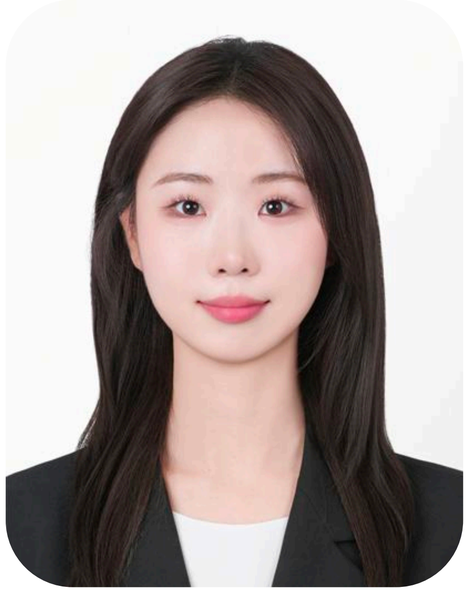
Lee Chaewon 이채원

데이터와 AI모델을 기반으로 실제 사용자 문제를 해결하는 엔지니어

누군가는 하던 일을 계속할 때, 해보지 않은 일에 도전하며 다양한 관점으로 문제를 해결해 왔습니다.



도전하는 마인드

문제 해결능력

지속적인 성장

Info

- 2003.06.18 생
- 2027.02 졸업예정
- 010-2383-5683
- codnjsruby12@gmail.com

Education

- 2022.03 - 2027.02 홍익대학교 산업데이터공학과 (GPA: 3.59/4.5)
- 2026.01 - 2026.02 Technische Universität Berlin (TU Berlin), Germany (Grade 1,3)

Career

- 2025.09 - 2025.12 (주)카카오 KAKAO Kanana 품질평가팀 Data & Research Assistant
- 2025 DGIST Intelligent Bio-OptoMechatronics Lab Summer Internship
- 2024.02 - 2024.12 Hongik University Artificial Intelligence Applications Lab

License

2025.09.14	TOEIC SPEAKING (Intermediate High 150)
2025.06.15	TOEIC (TOTAL SCORE 800)
2024.04.05	SQL 개발자
2023.09.15	ADsP 데이터분석 준전문가

Award

2026 5th AI Value Creation Club Demo Day - Excellence Project Award
모호한 커리어 고민을 구조화하고 답변 가능성을 판단해, 필요 시 적합한 AI 멘토를 연결하는 LLM 기반 커리어 멘토링 Agent 서비스

2025 DGIST Robotics Summer Interenship Research Competition (전체4위)
의료용 시계열, X-ray 데이터를 활용한 바늘 삽입 검출 및 안전성 판단 AI 모델·Computer Vision 파이프라인 연구

2024 codata station 데이터과학논술대회 - 협회의장상(전체7위)
대규모 혈액 수요 데이터를 기반으로 응급 혈액 드론의 최적 거점 배치와 기단 규모를 도출하는 ML가반 최적화 프로젝트

Paper

Asia Pacific Journal of Information Systems (APJIS) · First Author
Optimizing Drone-Based Emergency Blood Delivery Networks: A Data-Driven Approach for Station Placement and Fleet Sizing in Seoul

Skills

Programming & Data

- Python (상급): 대규모 데이터 전처리, ML/DL 모델 개발 및 평가, AI 파이프라인 구현
- SQL (중급): 관계형 데이터 조회 및 가공, 데이터 전처리 및 집계

LLM & AI Agent

- LLM / AI Agent (상급): Agent, Multi-Agent 설계, Tool Calling, LLM 평가 및 Agentic Workflow 구현
- RAG / Retrieval (상급): FAISS, BM25, Neo4j 기반 Hybrid Retrieval, Embedding, Grounding 파이프라인 구축

ML / DL & Computer Vision

- PyTorch (중급): 1D ResNet, MLP 기반 모델 학습, Loss, Sampling, Ablation Study 기반 성능 최적화
- Computer Vision (중급): YOLOv8, OpenCV 기반 객체 탐지, 영상처리 및 분류 모델 개발
- Machine Learning (상급): Scikit-learn, XGBoost, LightGBM 기반 모델링, Ensemble Learning 및 성능 평가

AI Service & Automation

- AI Service (상급): FastAPI, Streamlit, Next.js, TypeScript 기반 AI 서비스 및 API 구현
- Workflow Automation (중급): n8n, GitHub Webhook, Slack API 기반 LLM Agent 업무 자동화

Optimization & Simulation

- Optimization (상급): KDE, MCLP, K-means, VRP 기반 최적화 모델링 및 시뮬레이션

Project Type
EXPERIENCE

01
Work Experience

실제 AI 서비스 환경에서 데이터를 기반으로 문제를 정의하고,
모델과 Agent의 성능을 평가·분석하며 개선 방향을 도출했습니다.

2025 **Kakao**

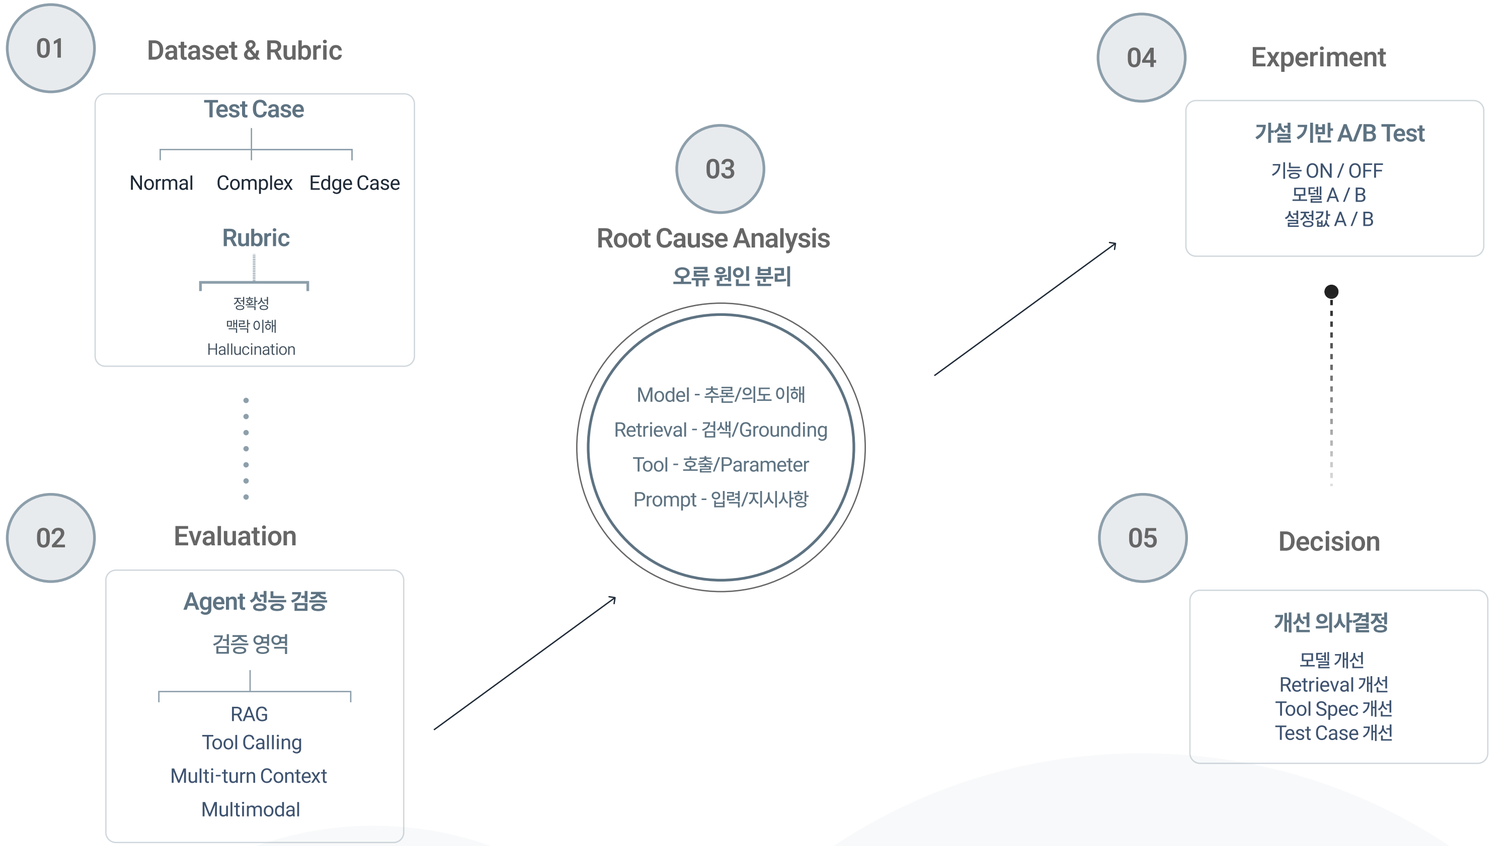
Data Research Assistant
LLM Agent Evaluation & Quality Optimization

카카오 | Data Research Assistant

▸ LLM Agent Evaluation & Quality Optimization

실서비스 LLM Agent의 RAG, Tool Calling, 멀티턴 응답을 평가하고,
데이터 기반 실험을 통해 오류 원인과 개선 우선순위를 도출한 AI Agent
품질 검증 프로젝트

Problem “Agent의 낮은 응답 품질이 모델 자체의 문제인지, RAG·Tool·Context 등 시스템 구성요소의 문제인지 구분하기 어려움”



Solution

❶ Evaluation Dataset

실서비스 시나리오와 Edge Case를 반영한 LLM·멀티모달 평가 데이터셋 및 루브릭 설계

❷ Agent Evaluation

RAG·Tool Calling·Context 활용 과정의 오류를 유형화하고 Root Cause 분석

❸ Experiment & Optimization

A/B Test 및 모델 비교 실험을 통해 Agent 기능·모델 변경에 따른 품질 개선 효과 검증

01. RAG & Tool-using Agent Evaluation

Problem | 왜 시작했는가

LLM Agent의 최종 응답은 모델의 추론 성능뿐 아니라 검색된 정보를 얼마나 정확하게 활용하는지, 사용자 요청에 맞는 Tool을 선택하고 올바른 Parameter로 호출하는지, 이전 대화의 Context를 적절하게 반영하는지에 따라 달라졌습니다.

따라서 응답을 단순 정답과 오답으로 평가하는 방식만으로는 실패가 모델 자체의 한계에서 발생했는지, Retrieval이나 Tool 연동 등 Agent 시스템의 문제에서 발생했는지 판단하기 어려웠습니다.

Hypothesis | 어떻게 풀 것인가

Agent 유형과 동작 방식에 맞춰 평가 기준을 세분화하고, 발견된 오류를 응답 생성 과정에 따라 추적한다면 최종 품질 점수를 넘어 실제 실패 원인과 개선이 필요한 지점을 특정할 수 있을 것이라 판단했습니다.

Approach | 무엇을 했는가

01 **AGENT 특성에 따른 EVALUATION RUBRIC 설계**

AGENT 특성에 따라 평가 지표를 다르게 정의

RAG - Grounding / 검색 결과와 응답 일치성
Tool Calling -Tool 선택 적절성 / Parameter 정확성
Context - 의도 이해 / 관련·비관련 정보 구분
Response - 정확성 / Hallucination / Safety / Format

02 **실서비스 TEST CASE 평가**

NORMAL / COMPLEX / EDGE CASE로 평가 데이터를 구조화하고 실제 사용자 입력을 기반으로 AGENT 응답 검증

03 **ROOT CAUSE ANALYSIS**

발견된 오류를 단순 오답으로 기록하지 않고
MODEL → RETRIEVAL → TOOL → PROMPT/CONTEXT
단계로 분리하여 원인을 분석

Result

Hallucination / Tool 호출 오류 /Context 활용 실패 등을 Failure Pattern으로 구조화

AGENT의 최종 응답을 단순 품질 점수로 평가하는 데서 벗어나 실패 원인을 MODEL, RETRIEVAL, TOOL, PROMPT/CONTEXT 수준으로 구분할 수 있는 평가 체계를 구축

모델 문제와 TOOL/RAG 스펙 문제를 분리하여 개발·기획 개선 우선순위 도출

Insight

LLM Agent의 품질은 개별 모델의 성능만으로 설명할 수 없으며, 사용자의 요청이 최종 응답으로 만들어지는 전체 Agent Pipeline을 함께 평가해야 실제 성능 병목을 찾을 수 있음을 확인했습니다.

02. 사용자 시나리오 기반 Agentic AI Workflow 성능 검증

Problem | 왜 시작했는가

일정 관리 Agent는 사용자의 요청을 이해하는 것에서 끝나지 않고, 사용자 의도를 파악한 뒤 적절한 Agent를 선택하고 날짜와 시간 정보를 추출해 Tool을 호출하는 전체 과정이 정상적으로 연결되어야 했습니다.

하지만 기존 기능별 Test Case만으로는 사용자마다 다른 일정 패턴과 표현 방식, 멀티턴 상황에서 발생하는 오류를 충분히 재현하기 어려웠습니다. 또한 최종 응답이 실패했을 때 LLM의 정보 추출 문제인지, Tool/API 연동 과정의 문제인지 구분하기 어렵다는 한계가 있었습니다.

Hypothesis | 어떻게 풀 것인가

실제 사용자 행동을 Persona와 일정 데이터로 재현하고 Workflow를 단계별로 검증한다면, 실사용 환경의 오류를 발견하고 발생 원인까지 구체화할 수 있을 것이라 판단했습니다.

Approach | 무엇을 했는가

01 30명 PERSONA 기반 실사용 데이터셋 구축

- 직업, 생활 패턴, 주요 사용 시간대가 다른 30명의 Persona를 설계하고 1인당 50~70개의 업무, 개인, 반복 일정을 구성해 총 1,800개의 일정 데이터 구축
- 실제 사용자의 Calendar Context를 재현하여 실서비스와 유사한 검증 환경 구성

02 실서비스 TEST CASE 평가

- 일정 요청을 FREQUENCY, INTERVAL, DATE, TIME, ACTION, TOOL 등의 핵심 요소로 분해
- 특정 변수를 통제하며 개별 요소에 대한 AGENT의 반응을 검증하는 방식으로 등록, 수정, 조회, 브리핑 등의 200개 이상 시나리오를 설계

03 WORKFLOW 단계별 ROOT CAUSE 분석

- 각 TEST CASE에서 사용자 입력 → AGENT 선택 → 정보 추출 → TOOL 호출 → 결과 반환 과정을 단계별로 추적
- 반복적으로 발생하는 오류를 유형화하고, LLM의 날짜/시간 정보 추출 문제와 TOOL/API 연동 문제를 분리해 실제 개선 지점을 도출

Result

사용자 요청을 놓치지 않고 정확히 처리한 비율(Recall) 개선

일정 등록 86% → 89%, 일정 수정 82% → 84%, 일정 조회 92% → 97%

반복 오류를 구조화하여 AGENT WORKFLOW의 실패 지점과 개선 우선순위를 확인할 수 있는 데이터로 전환

Insight

기능별 Test Case에서는 정상적으로 동작하더라도 실제 사용자별 일정 데이터와 멀티턴 Context가 결합되면 Agent Selection, 날짜 및 시간 정보 추출, Tool 호출 과정에서 새로운 오류가 발생할 수 있음을 확인했습니다.

Project Type
RESEARCH

02
LAB
Research

의료, 산업 데이터를 기반으로 연구 문제를 정의하고, ML/DL 모델을 설계하며 실험과 정량적 평가를 통해 가설을 검증했습니다.

2025 DGIST Intelligent Bio-OptoMechatronics Lab

- 의료용 광학 센서의 1D 시계열 데이터를 활용한 바늘 삽입(Puncture) 검출 모델 설계 및 개발
- X-ray 영상 기반 바늘 삽입 안전성 분석을 위한 실시간 Computer Vision 파이프라인 설계 및 개발

2024 Hongik University Artificial Intelligence Applications Lab

- 의료용 LLM 질의응답 4,000건을 분석하여 LLM-as-a-Judge 기반 응답 품질 평가 파이프라인 구현
- 정면/측면 X-ray 2장을 입력으로 3D CT 볼륨을 재구성하는 X2CT-GAN 기반 의료영상 생성 모델 구현

Research1

▸ 의료용 광학 센서의 1D 시계열 데이터를 활용한 바늘 삽입(Puncture) 검출 모델 설계 및 개발

01
Background

의료용 바늘 삽입 과정에서 광학 센서의 1D 시계열 신호를 기반으로 실제 조직 천공(Puncture) 시점을 자동으로 검출하는 모델이 필요했습니다.

하지만 전체 데이터에서 실제 Puncture가 발생하는 구간은 약 0.04%에 불과해, 일반적인 학습 방식으로는 모델이 대부분의 구간을 정상으로 판단하면서도 높은 정확도를 보이는 극심한 Class Imbalance 문제가 있었습니다.

따라서 희소한 Puncture 신호의 특징을 효과적으로 학습할 수 있도록 데이터 라벨링 및 샘플링 전략을 재설계하고, 시계열 신호의 Peak를 정확하게 구분하는 모델 구조를 탐색할 필요가 있었습니다.

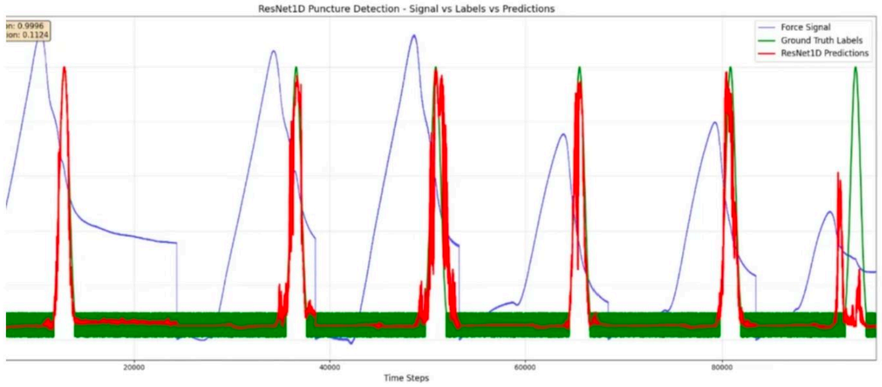
02
Solution

- 전체 신호의 0.04%에 불과한 Puncture 데이터 불균형 해결을 위한 5-Stage Confidence Labeling 및 Peak-Aware Sampling 설계
- 희소한 Puncture 신호의 Peak 검출을 위한 1D ResNet-18 모델 설계 및 Loss Function, Activation, Sampling 조건별 Ablation Study
- LSTM과 1D ResNet-18 비교 실험을 통한 시계열 신호 내 Puncture 구간 식별 성능 최적화
- Puncture와 정상 신호 구분 성능 ROC-AUC 0.9557(+4.5%p), 미학습 데이터 예측 오차(Validation Loss) 23% 감소

03
Skills

Python, PyTorch, 1D CNN, ResNet-18, Time Series Analysis, Deep Learning, Ablation Study, Focal Loss, Dice Loss

Result



Insight

전체 신호의 0.04%에 불과한 Puncture 데이터의 학습 한계 해소, 5-Stage Confidence Labeling과 Peak-Aware Sampling을 통한 희소 신호 학습 데이터 분포 구축

LSTM, Loss Function, Activation, Sampling 조건별 Ablation Study를 통한 광학 신호의 Puncture Peak 검출에 최적화된 1D ResNet-18 구조 선정

Puncture와 정상 신호 구분 성능 ROC-AUC 0.9557, 기존 LSTM 대비 4.5%p 향상, Validation Loss 23% 감소를 통한 미학습 데이터에서의 예측 안정성 개선

Research2

▸ X-ray 영상 기반 바늘 삽입 안전성 분석을 위한 실시간 Computer Vision 파이프라인 설계 및 개발

01

Background

X-ray 영상에서 바늘이 목표 영역에 안전하게 삽입되었는지를 판단하기 위해서는 바늘의 위치뿐 아니라 기준선과의 거리, 각도 등 공간적 관계를 함께 분석할 필요가 있었습니다.

하지만 X-ray 영상의 노이즈와 낮은 대비로 인해 바늘과 기준선을 안정적으로 검출하기 어려웠으며, 단순 객체 탐지만으로는 삽입 상태의 안전성을 판단하기 어렵다는 한계가 있었습니다. 이에 영상처리와 객체 탐지, 기하학적 특징 기반 분류를 결합한 단계별 Computer Vision Pipeline을 설계했습니다.

02

Solution

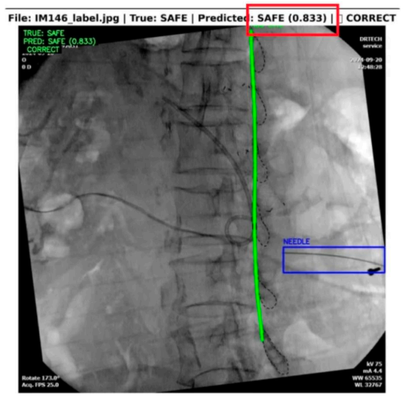
- HSV 기반 ROI 추출과 Morphological Operation을 적용하여 노이즈 환경에서 Red Line을 안정적으로 검출
- YOLOv8s 기반 Needle Detection 모델을 학습하고 데이터 증강을 통해 객체 검출 성능 및 일반화 성능 향상
- 20개의 기하학적 특징(Geometric Features)을 활용한 MLP 분류 모델 및 Softmax-weighted Ensemble 설계
- Binary·Multi-class 분류 성능을 비교 분석하여 최적의 안전성 판단 모델 구축

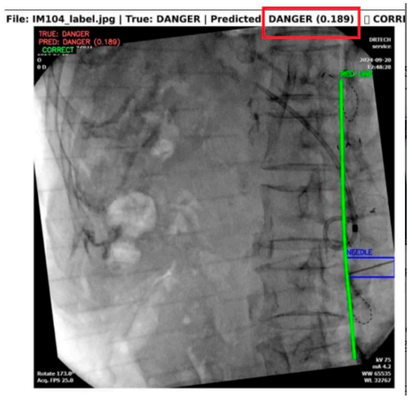
03

Skills

Python, PyTorch, 1D CNN, ResNet-18, Time Series Analysis, Deep Learning, Ablation Study, Focal Loss, Dice Loss

Result





Insight

X-ray 노이즈 환경에서도 바늘과 기준선을 안정적으로 식별하기 위한 Multi-Stage Vision Pipeline 구축, HSV 기반 영상처리와 YOLOv8 객체 탐지 결합

바늘과 기준선 사이의 거리, 각도 등 20개 기하학적 특징을 활용한 삽입 안전성 판단 모델 구축, MLP Ensemble 기반 정확도 87.25%, 정밀도와 재현율을 함께 반영한 F1-score 0.88 달성

Binary 및 Multi-class 모델 비교 실험을 통한 바늘 삽입 상태 구분 성능 검증 및 최적 안전성 판단 구조 도출

03
AI Service Projects

사용자와 산업의 문제를 정의하고, LLM Agent, RAG, Vision AI를 실제 서비스와 Workflow로 연결하는 AI 프로젝트를 수행했습니다.

2026	1. Career Mentoring Agent 2. SeoulFit Travel Agent 3. Disclosure Risk Detection Agent
2025	1. SDV Impact Analysis Agent 2. Food Recommendation AI
2024	1. Emergency Blood Delivery Optimization

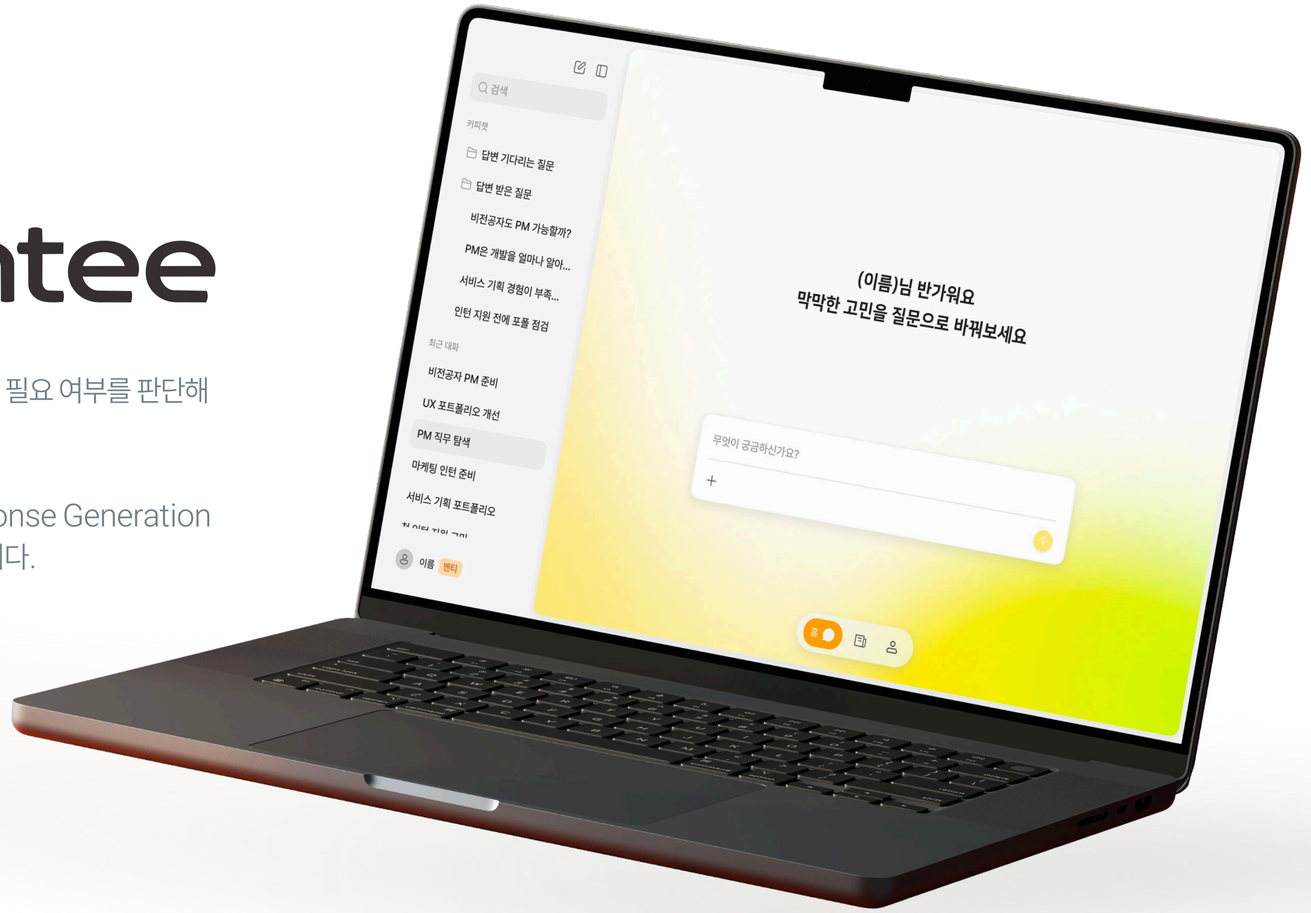
Project
01

2026.03 - 2026.08

진로 고민을 구조화하고
적합한 멘토로 연결하는
mentor to mentee

사용자의 모호한 진로 고민을 대화를 통해 구체적인 질문으로 정제하고, 추가 조언 필요 여부를 판단해 적합한 AI Mentor와 연결하는 **LLM 기반 커리어 멘토링 웹 서비스**입니다.

Question Refinement, Routing, Mentor Recommendation, Response Generation 으로 이어지는 Agentic AI Workflow를 설계하고 실제 웹 서비스로 구현했습니다.



Team 대학생 인공지능동아리(프로메테우스) 5인 프로젝트

Role 프론트, Ai agent 설계

Why M2M?

M2M은 “막연한 진로 고민을 가진 사용자에게 AI가 어떻게 더 구체적이고 개인화된 조언을 제공할 수 있을까?”라는 문제에서 시작한 AI 기반 커리어 멘토링 웹 서비스입니다.

진로 고민은 처음부터 명확한 질문으로 정리되지 않는 경우가 많고, 같은 고민이라도 사용자의 상황에 따라 필요한 조언과 관점이 달라집니다. 이에 단순히 질문에 답하는 챗봇이 아니라, 대화를 통해 고민을 구체화하고 적합한 AI Mentor를 찾아 개인화된 조언으로 연결하는 서비스를 기획했습니다.

Problem Discovery

초기에는 사용자의 진로 고민을 입력받아 LLM이 바로 답변을 생성하는 방식을 고려했습니다. 하지만 질문 자체가 모호한 상태에서는 일반적이고 추상적인 답변이 생성되고, 사용자가 실제로 해결하고 싶은 문제가 충분히 반영되지 않는 한계가 있었습니다. 이에 핵심 문제를 ‘좋은 답변을 생성하는 것’에서 ‘사용자의 모호한 고민을 답변 가능한 질문으로 구조화하고, 어떤 조언이 필요한지 판단하는 것’으로 재정의했습니다.

Design Decision

사용자의 입력에 즉시 답변하는 대신,
질문 정제 → 해결 가능 여부 판단 → Mentor 추천 → 개인화 답변 생성으로 이어지는 단계형 Agent Workflow를 설계했습니다.

먼저 Conversational AI가 사용자와 추가 대화를 통해 고민을 구체적인 질문으로 정제합니다. 이후 현재 보유한 커리어 지식으로 해결할 수 있는지를 판단하고, 추가적인 경험 기반 조언이 필요한 경우 질문과 적합도가 높은 AI Mentor Persona를 추천하도록 구성했습니다.

사용자가 Mentor를 선택하면 해당 Persona의 경험과 관점을 Context로 활용하여 동일한 질문에서도 Mentor에 따라 차별화된 답변을 생성하도록 설계했습니다.

Agent Pipeline

01 QUESTION REFINEMENT

사용자와의 대화를 통한 모호한 진로 고민의 구체화 및 핵심 질문 구조화

02 ROUTING

구조화된 질문을 바탕으로 기존 커리어 지식만으로 해결 가능한지, 추가 MENTOR 조언이 필요한지 판단

03 MENTOR RECOMMENDATION

사용자 질문과 MENTOR PERSONA의 특성을 기반으로 적합한 AI MENTOR 후보 추천

04 RESPONSE GENERATION

선택한 MENTOR의 경험과 관점을 CONTEXT로 활용한 개인화 커리어 조언 생성

Contributions

AI AGENT ARCHITECTURE

Question Refinement, Routing, Mentor Recommendation, Response Generation으로 이어지는 Multi-step Agent Workflow 설계

AI BACKEND

FASTAPI 기반 AGENT 실행 API 및 FRONTEND-AI 연동 구조 구현

FULL-STACK SERVICE

NEXT.JS, TYPESCRIPT, FASTAPI 기반 사용자 입력부터 MENTOR 선택, 최종 응답까지 END-TO-END 웹 서비스 구현

PROMPT & PERSONA DESIGN

질문 정제와 ROUTING을 위한 PROMPT 설계 및 MENTOR별 차별화된 답변 생성을 위한 PERSONA CONTEXT 구성

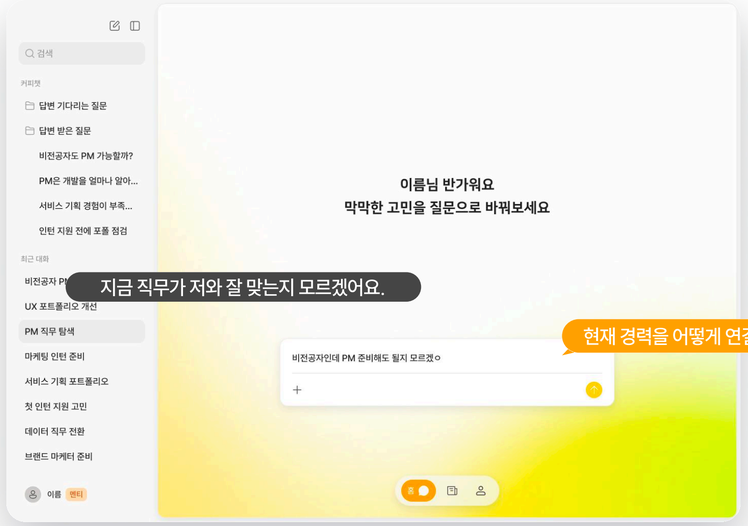
Result

Prometheus Demo Day 우수프로젝트상 수상

What I Learned

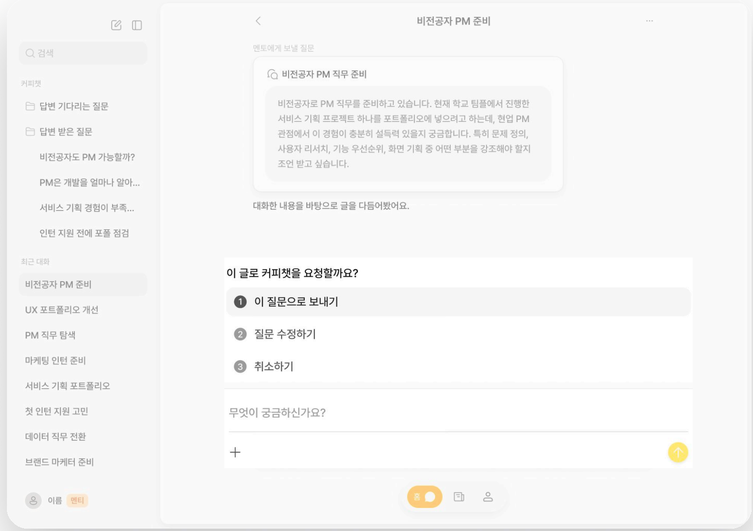
LLM 기반 서비스에서는 모델이 얼마나 좋은 답변을 생성하는지만큼 사용자의 문제를 어떻게 구조화하고, 어떤 상황에서 어떤 AI 기능을 실행할 것인지 설계하는 과정이 중요함을 경험했습니다.
또한 Agent 기능을 실제 웹 서비스로 구현하며 LLM, Backend API, 사용자 Interaction을 하나의 Workflow로 연결하는 End-to-End AI 서비스 개발 경험을 쌓았습니다.

01. 멘티 프로파일링 & 질문 구조화



멀티턴 대화로 현재 상태, 관심 직무, 보유 경험, 제약, 궁금한 점을 수집하며 멘티를 프로파일링하고
막연한 고민을 구조화된 질문으로 정리하고,
막힌 지점·위험 신호·검색 및 매칭 전략에 필요한 힌트를 메타데이터로 함께 변환합니다.

02. 검색,검증,분기



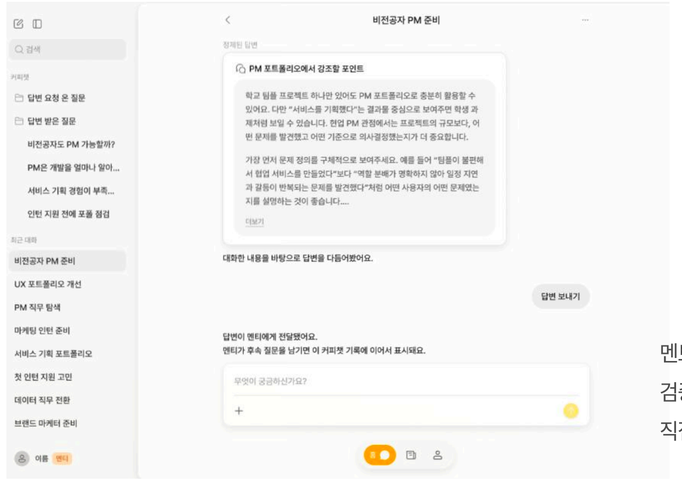
정제된 질문을 기존 멘토 답변 자산에서 임베딩 검색한 뒤, 관련성·근거 충분성·최신성·상황 적합성·개인정보
안전의 5가지 기준으로 검증합니다. 검증 결과에 따라 ① AI 직접 답변 ② 부분 답변과 멘토 추천 ③ 멘토 연결의 세 방향으로 분기하며, 단순 검색이 아니라 멘토의 도움이 꼭 필요한 질문인지 판단하는 것이 핵심입니다.

03. 멘토 매칭

백엔드에서 자동 매칭

멘티가 어디에서 막혔는지, 어떤 전환을 원하는지, 기존 역량을 어떻게 옮겨 활용할 수 있는지를 함께 반영합니다.
멘토 프로필·전환 경험·답변 이력의 3채널 임베딩에 규칙 필터와 품질 루프를 더해, LLM이 추천 근거와 함께 가장 적합한 멘토 3명을 선별합니다.

04. 답변 자산화



멘토의 1:1 답변은 양측 동의 후 개인 맥락·정보 밀도·시의성·기밀성을 기준으로 검증합니다.
검증된 답변은 임베딩과 태그로 저장해 Agent 2의 검색 자산으로 활용하며, 데이터가 쌓일수록 AI 직접 답변은 늘고 멘토에게는 개인 맥락이 중요한 질문만 전달됩니다.

Project
02

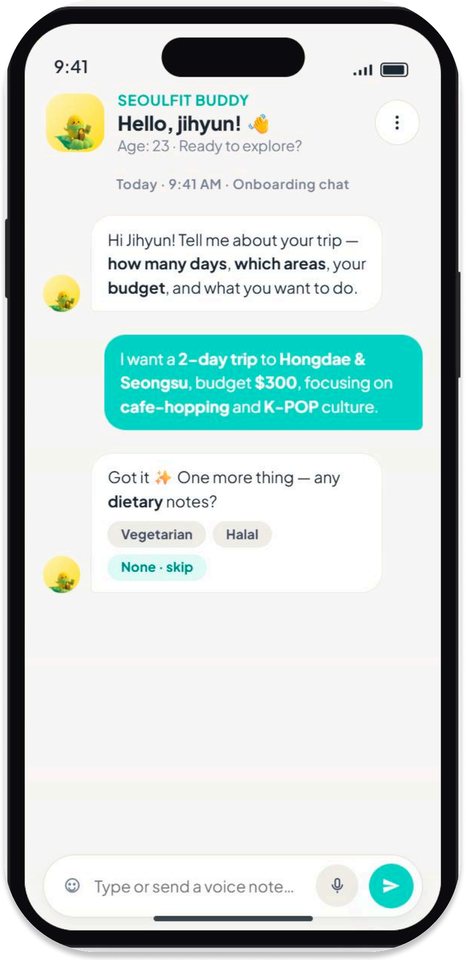
2026.03 - 2026.08

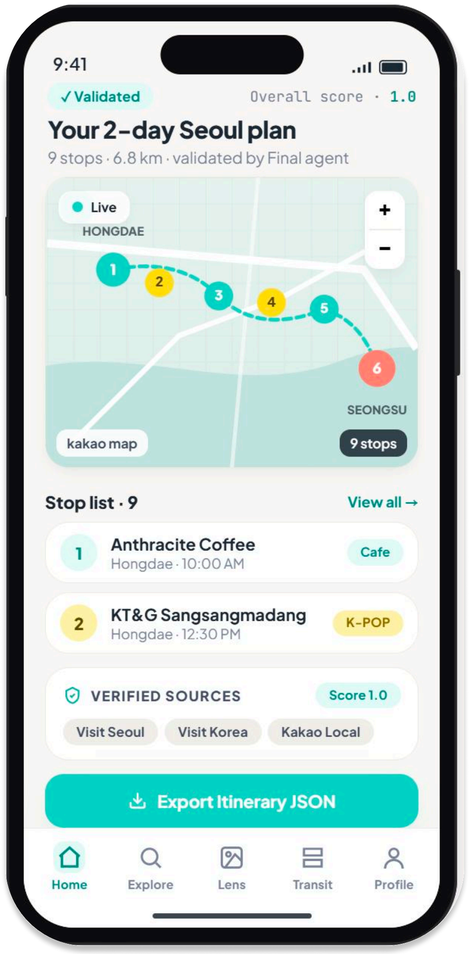
SEOULFit

외국인이 실제로 따라갈 수 있는 Agentic AI 여행 플래너, SeoulFit

LLM이 생성한 여행 일정을 RAG와 Critic Agent로 검증하고 자동 수정하여, 실제 실행 가능한 일정으로 변환하는 AI 여행 플래너 앱 서비스입니다.

기존 LLM 여행 플래너의 문제를 단순한 추천 정확도가 아닌 실행 가능성(Feasibility) 문제로 재정의했습니다. 실제 여행 코스를 기반으로 일정을 생성하고, 운영시간, 이동 동선, 식사, 외국인 이용 장벽을 Agent가 검증·수정하는 End-to-End AI 서비스를 개발했습니다.





Team	홍익대학교 산업데이터공학과 3인 프로젝트
Role	AI Pipeline, App Development

Why SeoulFit?

SeoulFit은 “LLM이 생성한 여행 계획은 왜 그럴듯하지만 실제로 따라가기 어려울까?”라는 문제에서 시작했습니다.

기존 AI 여행 플래너는 장소와 정보를 풍부하게 추천하지만, 사용자의 언어, 식단, 예산과 같은 제약을 실제 일정에 충분히 반영하지 못하거나 이동시간, 동선, 운영시간을 고려하지 않아 현실적으로 실행하기 어려운 계획을 생성하는 문제가 있었습니다. 실제 여행자의 경험 데이터를 검색하고 일정 생성 결과를 스스로 검증 및 수정하는 Agentic AI 기반 여행 플래너를 설계했습니다.

Problem Discovery

기존 AI 여행 플래너의 문제를 정량, 정성적으로 확인하기 위해 LLM 비교 실험과 실제 외국인 사용자 조사를 진행했습니다.

외국인, 영어 사용, 채식, 예산, K-pop, 전통문화 선호, 여유 있는 일정 등 현실적인 제약을 포함한 동일 프롬프트를 8개 LLM에 적용해 응답을 비교했습니다. 실제 장소 선정과 일정 구성에서는 제약 반영이 부족했고 이동 동선, 휴식, 일정 밀도까지 고려한 의사결정에 한계가 있었습니다.

동시에 홍익대학교 외국인 학생 대상 설문조사를 통해 문화·이용 규범, 이동 중 주변 장소 탐색, 정확한 가격, 로컬 이벤트 등 실제 여행에서 필요한 정보에 대한 수요를 확인했습니다.

Design Decision

❶ POI Retrieval → Experience RAG

기존 RAG는 장소별 정보 검색에는 강하지만 실제 여행자가 어떤 순서로 이동했는지에 대한 경험 흐름을 반영하기 어려워 블로그, 브이로그 등 **실제 여행 경험에서 방문 순서와 이동 흐름을 Sequence 데이터로 구조화**하고, 사용자 조건과 유사한 여행 경험을 검색하는 Experience RAG를 설계했습니다.

❷ One-shot Generation → Planner

LLM이 국적, 언어, 동반자, 식단, 예산, 일정 밀도 등의 사용자 제약과 Retrieval 결과를 함께 반영하여 장소 순서, 식사, 이동을 구성하는 Planner를 설계했습니다.

❸ Generate-only → Critic & Repair

일회성 생성만으로는 Hallucination, 운영시간 충돌, 비현실적인 동선이 그대로 노출될 수 있다고 판단했습니다. 이에 Critic이 실행 가능성, 경험 흐름, 외국인 적합성을 평가하고, 문제가 발견되면 Repair Agent가 자동 수정하는 검증 루프를 설계했습니다.

Agent Pipeline

User Input
국적, 언어, 동반자, 관심사, 식단, 예산

Constraint Parsing
사용자 의도 및 여행 제약 구조화

Experience RAG
실제 여행 Sequence 기반 유사 경험 검색

Planner Agent
사용자 제약 + Retrieval 기반 일정 생성

Critic & Repair Agent
실행 가능성, 경험 흐름, 외국인 적합성 검증/오류 및 제약 미반영 일정 수정

Final Itinerary
실행 가능한 개인화 여행 일정

Contributions

PROBLEM & EXPERIMENT
외국인 사용자 조사 기반 문제 정의, 현실 제약 Prompt 설계 및 8개 LLM 비교 평가

DATA & RAG
실제 여행 경로의 SEQUENCE 데이터 구조화, EXPERIENCE RAG 및 사용자 CONSTRAINT 데이터 설계

AGENT ARCHITECTURE
PLANNER – CRITIC – REPAIR 기반 MULTI-AGENT WORKFLOW 설계

EVALUATION
기존 GPT PRO를 BASELINE으로 설정하여 생성 품질뿐 아니라 실행 가능성과 사용자 경험을 비교할 수 있는 평가 체계를 설계

Result

한국관광콘텐츠랩 2026 관광데이터 활용 공모전 본선진출(진행중)
졸업프로젝트 발표회 1위

What I Learned

LLM 기반 서비스에서는 모델이 얼마나 좋은 결과를 생성하는지만큼 실제 사용자 경험을 어떤 데이터로 구조화하고, Retrieval과 Agent가 이를 어떻게 활용하도록 설계하는지가 중요함을 경험했습니다.
또한 Experience RAG, Planner, Critic, Repair를 하나의 Workflow로 연결하며, 사용자 문제 정의부터 데이터 설계, Agent Architecture, 성능 평가까지 이어지는 End-to-End Agentic AI 서비스 개발 경험을 쌓았습니다.

Project
03

2026.03 - 2026.05

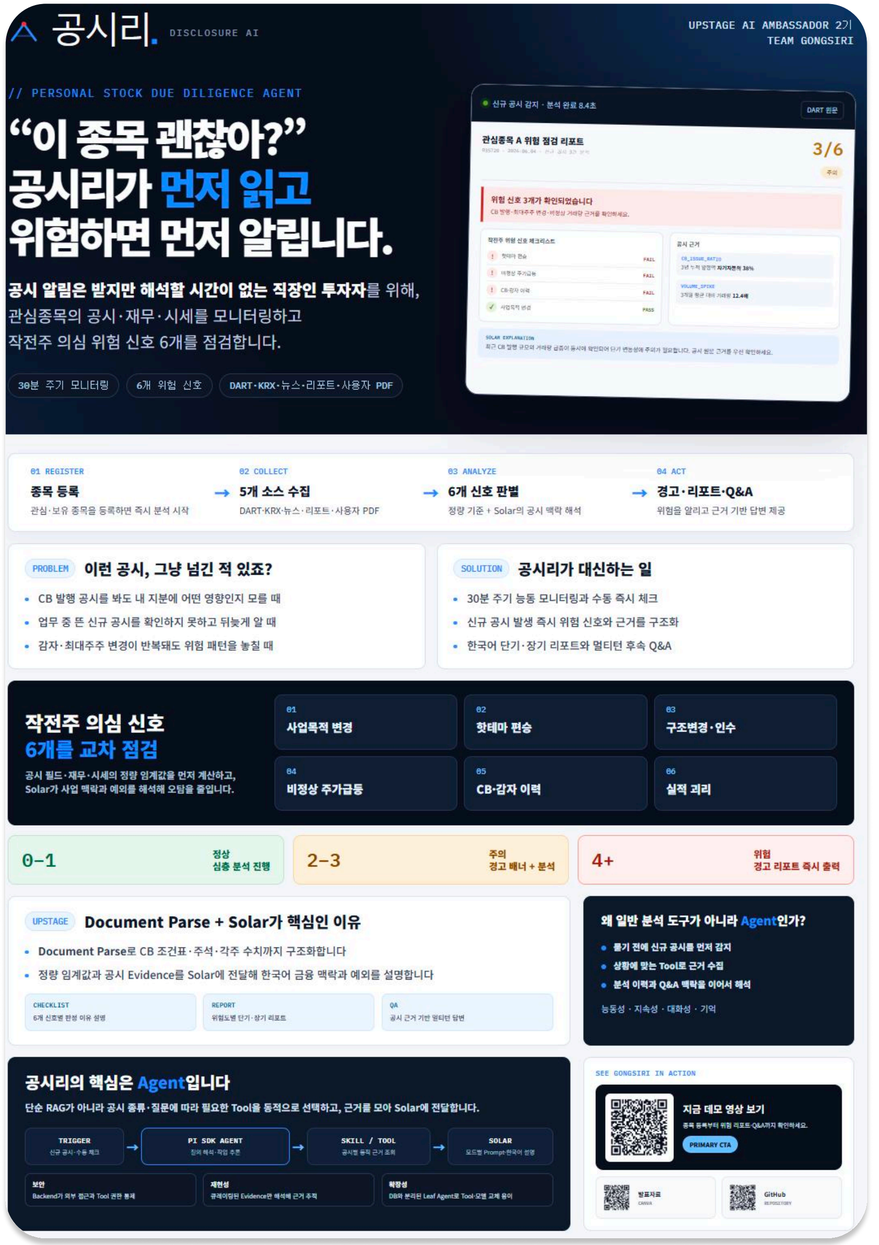
공시 속 위험 신호를 탐지하는 주식 분석 AI Agent, 공시리

관심 종목의 공시, 재무, 시세, 뉴스 데이터를 통합 분석하여 **개인 투자자가 놓치기 쉬운 위험 징후를 탐지하고, 판단 근거를 이해하기 쉬운 리포트로 제공하는 주식 분석 웹 서비스**입니다.

다중 금융 데이터를 AI가 해석 가능한 Context로 구조화하고, Rule-based Risk Detection → LLM Interpretation → Report Generation → Grounded Q&A로 이어지는 AI 분석 Workflow를 설계했습니다.

Team Upstage AI Ambassador 2기, 3인 프로젝트

Role AI Agent · AI Pipeline



Why 공시리?

개인 투자자가 기업의 위험 신호를 파악하려면 수백 페이지의 공시와 리포트를 직접 읽고, 시세, 거래량, 뉴스까지 함께 비교해야 합니다.

기존 서비스는 공시 알림이나 개별 정보 제공에는 강하지만, 여러 데이터를 연결해 위험 여부와 그 근거까지 해석하는 과정은 여전히 투자자의 몫이었습니다. 이에 공시리는 단순 공시 요약을 넘어, 여러 금융 데이터를 연결해 위험 신호를 선제적으로 탐지하고 근거까지 설명하는 AI Agent를 목표로 설계했습니다.

Problem Discovery

기존 투자 정보 서비스의 흐름을 분석한 결과, 공시 확인 → 관련 정보 탐색 → 위험 여부 판단 → 후속 분석이 서로 분절되어 있었습니다.

특히 감자, CB, 최대주주 변경 등의 중요 공시는 단일 문서만으로 위험을 판단하기 어렵고, 공시 원문, 재무정보, 주가·거래량, 뉴스 등 서로 다른 형태의 데이터를 함께 해석해야 한다는 문제가 있었습니다.

문제를 '공시를 쉽게 요약하는 것'이 아니라, 분산된 금융 데이터를 하나의 분석 Context로 연결해 위험 신호와 판단 근거를 함께 제공하는 것으로 재정의했습니다.

Design Decision

❶ Raw Data → AI-Readable Data Bundle

DART 공시, KRX 시세·거래량, 뉴스, 증권사 리포트 등 형식이 다른 데이터를 하나의 분석 입력으로 사용하기 어렵다는 문제가 있었습니다. 이에 공시 원문, 뉴스, 시세·거래량, 파싱된 리포트를 단일 Data Bundle로 정규화하고, 비정형 PDF는 Document Parse를 활용해 구조화하여 Agent가 일관된 Context에서 분석할 수 있도록 설계했습니다.

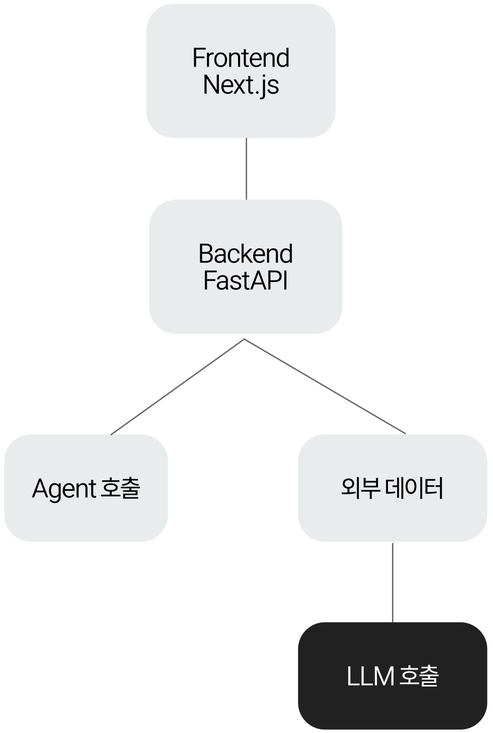
❷ LLM-only Analysis → Rule + LLM

금융 위험도를 LLM의 주관적인 판단에만 의존하면 동일한 데이터에서도 판정이 달라지고, 근거 없는 해석이 발생할 수 있다고 판단하여 6개 위험 항목을 Rule-based Checklist로 먼저 판정하고, Solar는 정량 판정과 원본 Context를 바탕으로 "왜 위험한지"를 설명하는 역할에 집중하도록 분리했습니다.

❸ One-shot Report → Grounded Agent

리포트 생성 이후 사용자가 추가 질문을 하면 최초 분석과 다른 Context에서 답변하거나 데이터에 없는 내용을 생성할 가능성이 있었습니다. 따라서 리포트와 후속 Q&A가 동일한 Data Bundle과 위험 판정 결과를 Grounding Context로 공유하도록 설계하고, 데이터에 없는 내용은 명시하고 투자 권유는 하지 않도록 출력 경계를 설정했습니다

시스템 아키텍처

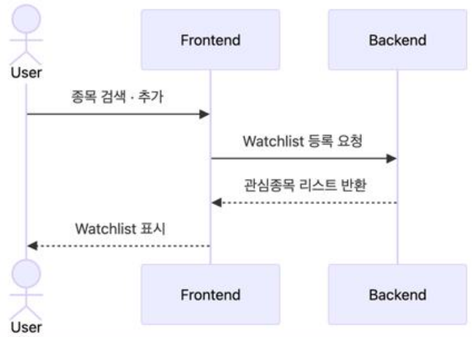


AI Analysis Pipeline

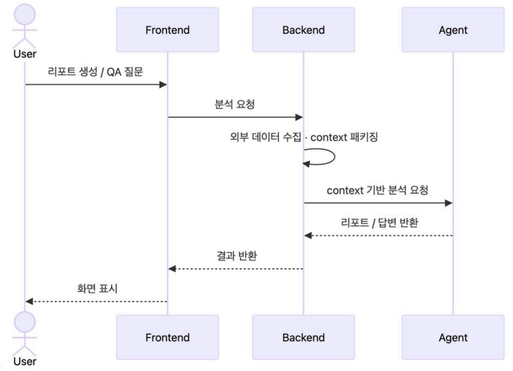
Multi-source Financial Data → Parsing & Normalization
→ Checklist Engine → Risk Classification → Solar Interpretation
→ Report Generation → Grounded Q&A

사용자 흐름

관심 종목 검색 및 추가



리포트생성 및 QA



What I Learned

LLM 기반 금융 서비스에서는 모델이 얼마나 자연스러운 분석을 생성하는지만큼 어떤 데이터를 근거로 제공하고, 정량적 판단과 LLM의 역할을 어떻게 분리할 것인지 설계하는 과정이 중요함을 경험했습니다.

또한 공시, 시세, 뉴스, 비정형 문서를 AI-Readable Context로 구조화하고 Risk Detection, LLM Interpretation, Grounded Q&A를 하나의 Workflow로 연결하며, 데이터부터 Agent 실행까지 이어지는 AI 시스템 설계 경험을 쌓았습니다

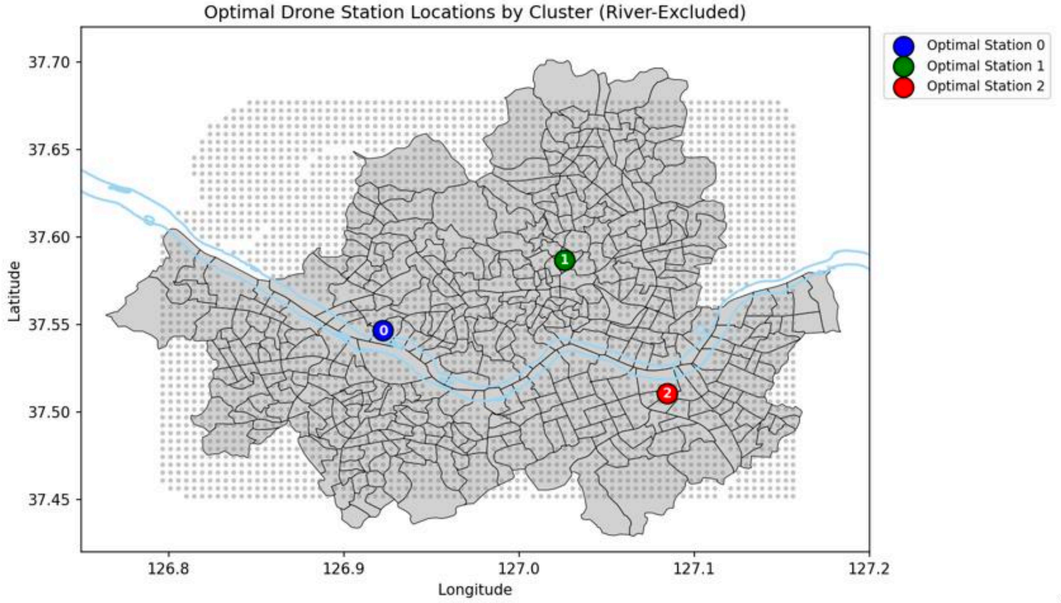
Project
04

2024.06 - 2024.12

실제 혈액 수요 데이터로 설계한 응급 혈액 드론 배송 최적화 시스템

대한적십자사의 5년간 혈액 출고 데이터 937,409건과 서울시 366개 병원 데이터를 기반으로, 응급 혈액 배송을 위한 드론 스테이션 입지와 필요 기체 수를 최적화한 데이터 기반 의사결정 시스템입니다.

KDE, MCLP, K-means를 결합해 수요 기반 스테이션을 선정하고, 실제 상용 드론의 비행거리, 적재량, 충전·로딩시간을 반영한 시뮬레이션으로 운영 가능성을 검증했습니다.



Team	팀명 : 무스탕시금치, 5인 프로젝트
Role	Data Analysis, Optimization Modeling, Simulation
Research	**1st Author**, Asia Pacific Journal of Information Systems(APJIS)

Why this Project?

혈액은 수요 변동성이 크고 보관기한이 제한되어 있어, 필요한 시점에 병원으로 빠르게 공급하는 것이 중요합니다. 그러나 기존 혈액 배송은 도로 교통에 의존하기 때문에 교통 혼잡 상황에서 응급 배송 시간이 증가할 수 있습니다.

이에 "실제 병원별 혈액 수요를 기반으로 드론 배송 거점을 재배치하면 응급 혈액 배송 효율을 얼마나 개선할 수 있을까?"라는 문제에서 프로젝트를 시작했습니다.

Problem Discovery

5년간 혈액 출고 데이터를 분석한 결과, 병원별 일일 수요는 평균 42.24팩, 중앙값 5팩으로 극심한 Right-skewed Distribution을 보였습니다.

또한 서울 25개 자치구별 수요와 기존 3개 혈액원의 위치를 분석한 결과, 고수요 병원이 특정 지역에 집중되어 있는 반면 일부 병원은 기존 혈액원에서 최대 13.73km 떨어져 있어 현재 위치가 드론 배송에도 최적인지 별도 검증이 필요했습니다.

따라서 단순 평균 수요와 기존 혈액원 위치를 사용하는 대신, Peak Demand와 공간적 수요 분포를 함께 반영한 새로운 배송 네트워크가 필요하다고 판단했습니다.

Design Decision

❶ Mean Demand → Q95 Demand

평균값만으로는 고수요 상황을 충분히 반영하기 어렵다고 판단해, 병원별 일일 출고량의 95th Percentile(Q95)을 운영 수요 기준으로 정의했습니다.
Mean, Median, Q90, Q95, Q99를 비교한 Sensitivity Analysis에서도 입지 결과는 대부분 유지되는 반면 필요 기체 수는 수요 기준에 따라 크게 달라짐을 확인했습니다.

❷ Location Only → Demand-aware Optimization

KDE로 혈액 수요 밀도를 추정하고 MCLP로 커버리지를 고려한 후보지를 생성했습니다.
이후 366개 병원을 3개 서비스 권역으로 구분하고, Q95 수요를 가중치로 적용한 이동거리 최소화를 통해 권역별 최종 스테이션을 선정했습니다.

❸ Optimization → Operational Simulation

입지 최적화만으로 실제 운영 가능성을 판단할 수 없기 때문에 Wingcopter 198과 DJI FlyCart30의 비행거리, 속도, 적재량을 적용했습니다.
여기에 로딩 및 충전시간까지 반영한 4개 운영 시나리오를 구성하여 병원 Coverage, 배송거리, 필요 운항 횟수, Fleet Size까지 검증했습니다.

Optimization Pipeline

Blood Release & Hospital Data
937,409건 혈액 출고 데이터 + 병원 위치 데이터

↓

Demand Modeling
병원별 Daily Demand 집계 → Q95 Peak Demand 산출

↓

KDE & MCLP
공간 수요 밀도 분석 → Coverage 기반 Candidate Site 생성

↓

K-means Clustering
366개 병원 → 3개 배송 권역 구분

↓

Demand-weighted Optimization
Q95 × Distance 기반 권역별 최적 Station 선정

↓

Drone Simulation
Range · Payload · Speed · Loading · Charging 반영

↓

Network Evaluation
Coverage · Delivery Distance · Fleet Size 비교

Contributions

프로젝트에서 데이터 전처리부터 수요 모델링, 입지 최적화, 드론 운영 시뮬레이션 및 결과 검증까지 전체 분석 프로세스를 수행했습니다.

DATA PROCESSING & DEMAND MODELING
대한적십자사 혈액 출고 937,409건과 병원 위치 데이터를 결합하고, 병원별 일일 수요의 편향을 반영한 Q95 기반 수요 지표 설계

OPTIMIZATION MODELING
KDE, MCLP, K-MEANS를 결합한 후보지 선정 및 권역 분할, Q95 수요 가중 이동거리 기반 최적 스테이션 입지 선정

SIMULATION & FLEET SIZING
상용 드론의 비행거리, 속도, 적재량, 로딩 및 충전시간을 반영한 배송 시뮬레이션과 최소 필요 기체 수 산정

EVALUATION & VALIDATION
기존 혈액원 대비 배송거리와 FLEET SIZE 개선 효과 비교, MEAN, MEDIAN, Q90, Q95, Q99 기반 SENSITIVITY ANALYSIS로 결과 안정성 검증

Result

2024 CO-Data Station 논문 경진대회 협의회장상 (전체 7위)
1st Author, Asia Pacific Journal of Information Systems(APJIS)

What I Learned

실제 운영 문제에서는 최적화 모델의 성능만큼 현실의 수요를 어떤 데이터로 정의하고, 실제 운영 제약을 어떻게 모델에 반영하는지가 중요함을 경험했습니다.
또한 실제 대규모 데이터를 수요 분석 → 데이터 모델링 → 입지 최적화 → 운영 시뮬레이션 → 성능 검증으로 연결하며, 데이터를 실제 의사결정 가능한 시스템으로 전환하는 End-to-End 분석 경험을 쌓았습니다.

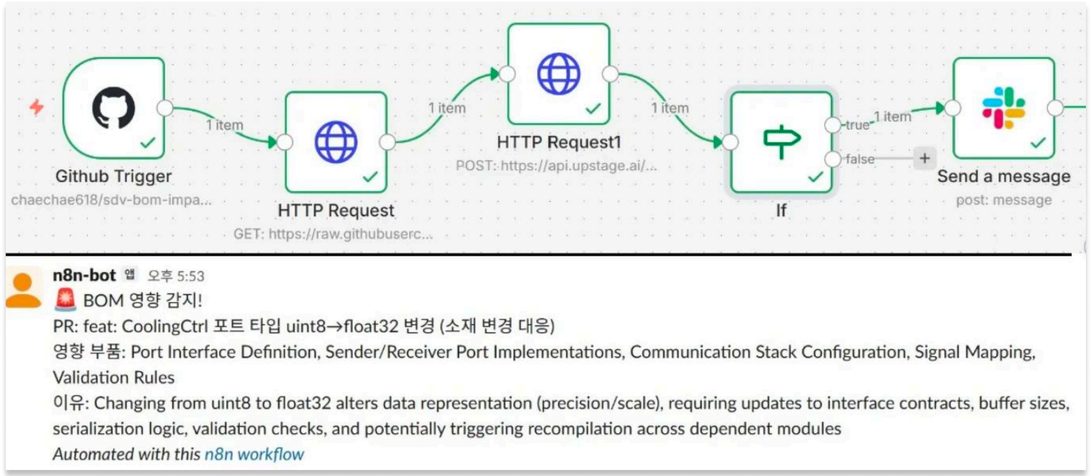
Project
05

2025.09 - 2025.12

ECU 변경이 하드웨어에 미치는 영향을 **자동 추적하는 AI Agent**

SDV 개발 과정에서 ECU 소프트웨어 변경이 BOM, 인터페이스, 통신 설정 등 연관된 하드웨어 구성에 미치는 영향을 자동 분석하는 LLM 기반 업무 자동화 Agent입니다.

GitHub Pull Request를 Trigger로 AUTOSAR 파일의 변경 정보를 수집하고, LLM이 SW–HW 간 의존성을 추론하여 영향 부품과 조치 필요 사항을 판단한 뒤 Slack으로 전달하는 Agentic AI Workflow를 설계했습니다.



Team Upstage AI Ambassador 2기, 개인 프로젝트

Role AI Workflow & Agent Architecture

Why this Project?

SDV에서는 하나의 ECU 소프트웨어 변경이 인터페이스, 통신 설정, BOM 등 여러 구성 요소에 연쇄적인 영향을 줄 수 있습니다. 그러나 개발자가 PR과 AUTOSAR 설정을 직접 확인하며 영향 범위를 추적해야 해 반복적인 검토 비용과 변경 영향 누락 가능성이 존재했습니다.

이에 코드 변경을 자동 감지하고, LLM이 SW–HW 의존성을 추론하여 영향 부품과 조치 사항까지 전달하는 AI Agent를 설계했습니다.

Problem Discovery

ECU Port Type 변경은 관련 Interface, Communication Stack, Signal Mapping 등으로 이어질 수 있기 때문에, 변경사항을 넘어 실제 영향 범위를 추론하는 과정이 필요했습니다.

Problem
ECU 변경마다 SW–HW 의존성을 수동 추적해야 해 반복 검토와 영향 범위 누락이 발생합니다.

Hypothesis
변경 감지 → Context 추출 → 영향도 추론 → 결과 전달을 Agent Workflow로 연결하면 변경 영향 분석을 자동화할 수 있습니다.

Design Decision

❶ Manual Check → Event-driven Trigger

사용자가 Agent에게 매번 분석을 요청하는 방식이 아니라, GitHub Pull Request 자체를 Agent 실행 Trigger로 설정했습니다. PR이 생성되면 Webhook을 통해 변경된 ECU 관련 파일을 자동으로 감지하여 실제 개발 Workflow 안에서 Agent가 실행되도록 설계했습니다.

❷ Raw Diff → Structured Context

AUTOSAR .arxml에서 Port Type, Interface, Signal Mapping 등 핵심 변경 정보를 추출하여 LLM의 추론 Context로 구성했습니다.

❸ Change Summary → Impact Reasoning

LLM의 역할도 변경사항 요약이 아니라 변경된 요소가 BOM, Interface Contract, Communication Stack, Buffer, Validation Rule 등에 어떤 영향을 미치는지 추론하는 것으로 정의했습니다.

Agentic AI Workflow

01 GITHUB PR TRIGGER
ECU 변경 자동 감지

02 AUTOSAR PARSING
PORT, INTERFACE, SIGNAL MAPPING 추출

03 LLM IMPACT REASONING
SW–HW 의존성 및 영향 범위 추론

04 RISK & DEPENDENCY MAPPING
영향 부품 및 필요 조치 도출

05 SLACK ACTION
분석 결과 자동 전달

Evaluation

Dependency Reasoning
- ECU 변경으로부터 BOM, Interface, Communication 설정 등 관련 영향 범위 도출 여부 검증

Workflow Execution
- GitHub PR → LLM 분석 → Slack 전달까지 End-to-End Pipeline 실행 검증

Response Time
- PR 발생 후 약 30초 내 영향 부품 및 조치 사항 전달

Contributions

문제 정의부터 LLM Reasoning Logic, Agent Workflow 및 Tool 연동 구조 설계까지 AI 영역 전반을 수행했습니다.

PROBLEM & USE CASE
ECU 변경 영향 분석 문제 정의 및 SW–HW Dependency 기반 Agent Use Case 설계

DATA & CONTEXT
AUTOSAR 변경 요소 추출 및 LLM 추론용 CONTEXT 구조 설계

AGENT ARCHITECTURE
GITHUB TRIGGER → PARSING → LLM REASONING → DEPENDENCY MAPPING → SLACK WORKFLOW 설계

AUTOMATION
SOLAR PRO, N8N, GITHUB WEBHOOK, SLACK API 기반 자동화 POC 구현

What I Learned

LLM 기반 업무 자동화에서는 모델 자체보다 언제 Agent를 실행하고, 어떤 Context를 제공하며, 추론 결과를 다음 Tool과 어떻게 연결할지 설계하는 과정이 중요함을 경험했습니다.
또한 GitHub, LLM, Slack을 연결하며 Trigger → Context → Reasoning → Action으로 이어지는 End-to-End Agentic AI Workflow 설계 경험을 쌓았습니다.

Project
06

2025.03 - 2025.08

음식 사진을 인식해
개인화 영양 추천으로 연결하는 Vision AI

사용자가 촬영한 음식 이미지를 YOLOv8 기반 Vision Model로 인식하고, 인식 결과를 영양소 기반 음식 추천 및 진단 시스템의 입력으로 연결하는 개인화 음식 추천 앱 서비스입니다.

음식 이미지 데이터 전처리, YOLOv8 학습·Fine-tuning, 성능 검증 및 서비스 추론 모듈 구현을 담당했습니다.



Team	대학생 인공지능동아리(프로메테우스) 5인 프로젝트
Role	Vision AI / Data Pipeline / Model Training & Evaluation

Why this Project?

음식 추천을 위해서는 먼저 사용자가 무엇을 먹었는지 정확히 알아야 했습니다. 기존 음식 추천 서비스는 사용자가 직접 음식명이나 섭취 정보를 입력해야 하기 때문에 입력 과정의 번거로움이 있었습니다.

이에 음식 사진 한 장만으로 현재 섭취 음식을 인식하고, 그 결과를 영양 정보 및 추천 시스템으로 전달하는 구조를 설계했습니다. 이 과정에서 제가 해결하고자 한 핵심 문제는 다양한 음식 이미지를 실제 서비스에서 안정적으로 인식할 수 있는 Vision Model을 구축하는 것이었습니다.

Problem Discovery

적은 GT 데이터만으로는 다양한 음식 이미지를 학습하기 어려웠습니다. 또한 초기 데이터는 음식별 정답 라벨이 존재하는 이미지로 제한되어 있었고, 실제 서비스 환경에서 나타나는 촬영 각도, 배경, 음식 형태 등의 다양성을 충분히 반영하기 어려웠습니다.

반면 활용 가능한 미라벨 음식 이미지는 훨씬 많았기 때문에, 모든 데이터를 수작업으로 라벨링하기보다 기존 GT 데이터를 활용해 학습 데이터를 확장할 수 있는 파이프라인이 필요하다고 판단했습니다.

따라서 데이터 확보 → 학습 → 검증 → 추가 학습으로 이어지는 모델 개발 프로세스를 구축하는 방향으로 문제를 해결했습니다.

Design Decision

❶ Pretrained Model → Domain Fine-tuning

음식 인식 모델을 처음부터 학습하지 않고 Pretrained YOLOv8s를 음식 이미지 데이터에 Fine-tuning했습니다. 음식별 이미지와 Bounding Box Label을 YOLO Format으로 정리하고 Dataset YAML을 구성하여 음식 도메인에 맞게 모델을 학습했습니다.

❷ Data Pipeline → Dataset Expansion

제한된 GT 데이터만 사용하는 대신 기존 라벨 데이터를 기반으로 추가 음식 이미지까지 활용할 수 있는 데이터 파이프라인을 구성했습니다.
이를 통해 약 10,000장의 GT 데이터에서 시작해 미라벨 데이터를 활용하며 학습 데이터 규모를 확장하는 방향으로 설계했습니다.

❸ One-shot Training → Iterative Evaluation

mAP50을 기준으로 Best Epoch와 Checkpoint를 확인하고 Fine-tuning을 진행했습니다.

Vision AI Pipeline

01 IMAGE DATA PREPROCESSING

음식 이미지, Bounding Box Label 정리 및 Dataset 구성

02 YOLOV8 FINE-TUNING

PRETRAINED YOLOV8S 기반 음식 DETECTION MODEL 학습

03 MODEL EVALUATION & FINE-TUNING

MAP50 기반 BEST EPOCH 및 CHECKPOINT 선정
BEST MODEL 기반 추가 학습 및 음식 DOMAIN 적응

04 FOOD DETECTION

입력 이미지에서 음식 CLASS 및 CONFIDENCE 추론

05 RECOMMENDATION PIPELINE

인식된 음식 정보를 후속 영양 추천 시스템의 입력으로 전달

Result

User Validation & Improvement

데모데이에서 약 30명의 사용자를 대상으로 음식 업로드 – 인식 – 추천 전체 Flow를 테스트하고 사용자 피드백 수집

→ 웹 배포 오류 및 음식 인식·추천 이해도 관련 피드백을 반영해 서비스 개선 후 재배포

Contributions

프로젝트에서 음식 이미지 데이터 구축부터 YOLOv8 학습, 성능 검증 및 서비스 추론 연결까지 Vision AI 파이프라인을 담당했습니다.

DATA PIPELINE

음식 이미지·Bounding Box Label 전처리 및 YOLO 학습 Dataset 구성

MODEL DEVELOPMENT

PRETRAINED YOLOV8S 기반 음식 DETECTION MODEL FINE-TUNING 및 추가 학습

EVALUATION

BEST CHECKPOINT 선정 및 PREDICTION 결과 검증

AI APPLICATION

학습된 모델을 활용해 음식 CLASS·CONFIDENCE를 반환하는 추론 모듈 구현 및 추천 PIPELINE 입력으로 연결

What I Learned

Vision AI 서비스에서는 모델 Architecture 자체만큼 어떤 데이터를 구성하고, 학습 결과를 어떤 지표로 검증하며, 실제 서비스의 입력으로 어떻게 연결하는지가 중요함을 경험했습니다.
또한 음식 이미지 데이터 전처리부터 YOLOv8 Fine-tuning → Evaluation → Inference까지 수행하며, Vision Model을 실제 AI 서비스 Pipeline의 한 단계로 연결하는 End-to-End 모델 개발 경험을 쌓았습니다.

Thank you

모호한 문제를 AI가 풀 수 있는 문제로 바꾸는
AI Engineer, 이채원

문제를 정의하고 가설을 세운 뒤, 데이터를 구조화하고 직접 실험하며 더 나은 해결책을 찾아가는 과정을 반복해왔습니다.
ML/DL 모델부터 LLM, RAG, AI Agent까지 필요한 기술을 선택해 적용하며 문제 정의에서 실험·평가, 실제 Workflow 설계까지 연결하는 역량을 쌓았습니다.
데이터와 AI 모델을 실제 문제 해결로 연결해, 사용자가 체감할 수 있는 AI 시스템을 만들어 나가고 싶습니다.

codnjsruby12@gmail.com
010 • 2383 • 5683